

人脸民族特征抽取及识别

——基本原理与关键技术

肖雅夫 2015年6月5日

NOTICE

- 注意：本PPT讲解的LDA指线性判别分析（Linear Discriminant Analysis），非主题模型LDA（Latent Dirichlet Allocation）

Content

- 1. 论文简介
- 2. 民族人脸识别总体方案
- 3. 二元LDA线性判别分析
- 4. 多元LDA线性判别分析

1. 论文简介

1.1 论文基本信息

- 题目：人脸的民族特征抽取及其识别
- 作者：段晓东，王存睿，刘向东，刘慧
(大连民族学院非线性信息技术研究所，东北大学研究生院)
- 期刊：计算机科学，2010年8月
- 数据集：作者自建数据集，包含我国17个民族

1.2 论文贡献

- 论文解决了什么问题？

验证了代数特征和几何特征对于民族人脸识别的可行性

- 论文尚未解决哪些问题？

没有处理光照变化和姿态变化

1.3 论文涉及到的算法思想

- 涉及到的算法、思想或技术：

- (1) 线性判别分析LDA

- (2) 人脸弹性模板

- (3) 积分投影

- (4) Gabor小波

- (5) 人脸拓扑结构

- (6) 决策树C5.0算法

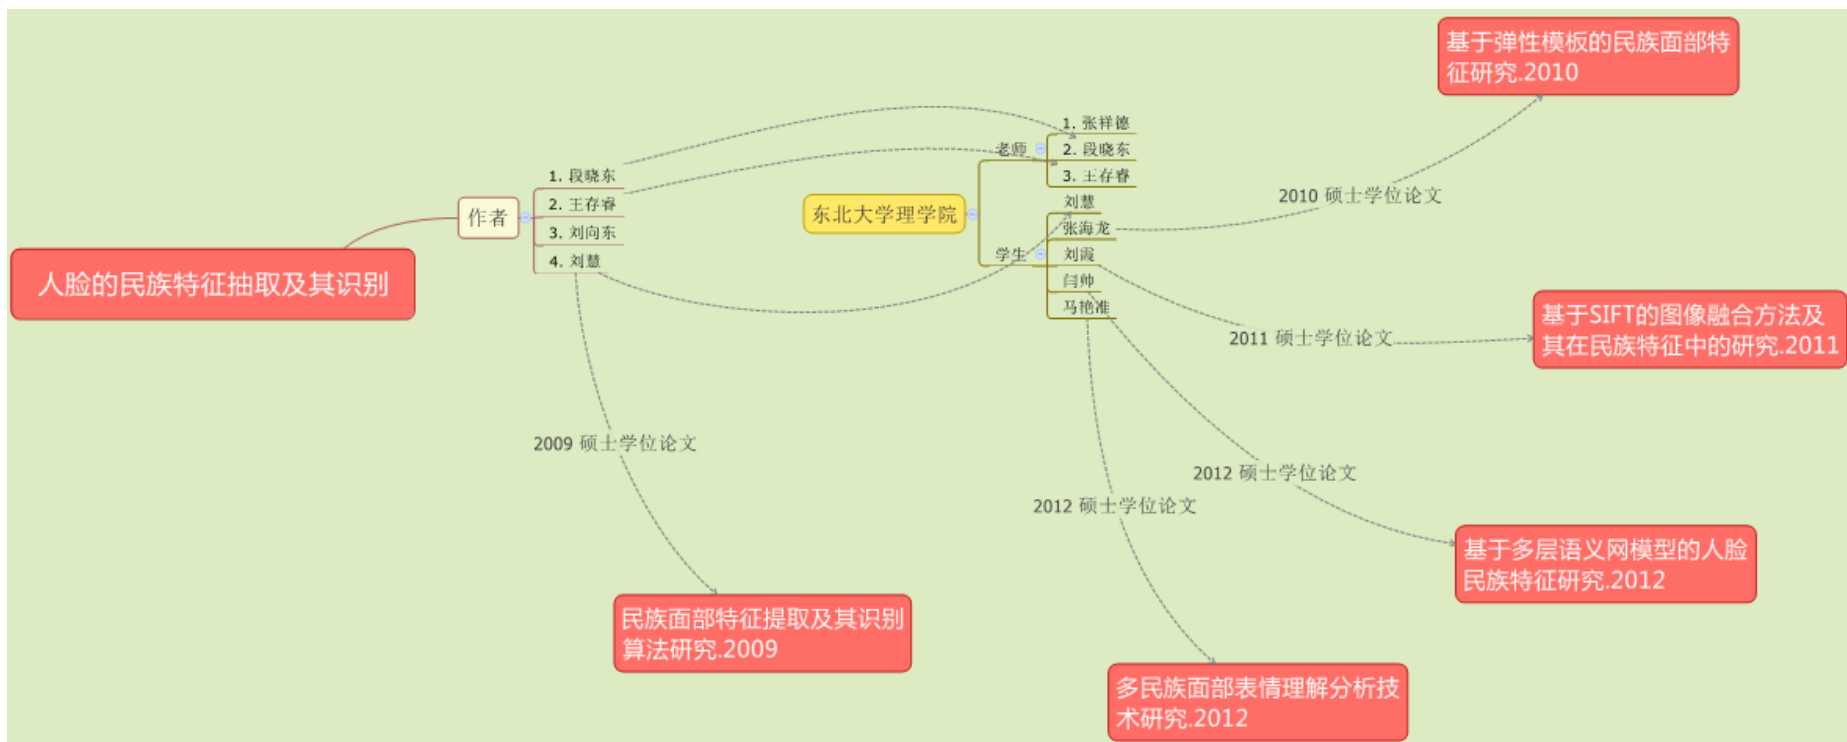
1.4 辅助参考文献

- 辅助参考文献:

张海龙.基于弹性模板的民族面部特征研究[D].东北大学.2010

刘慧.民族面部特征提取及其识别算法研究[D].东北大学.2009

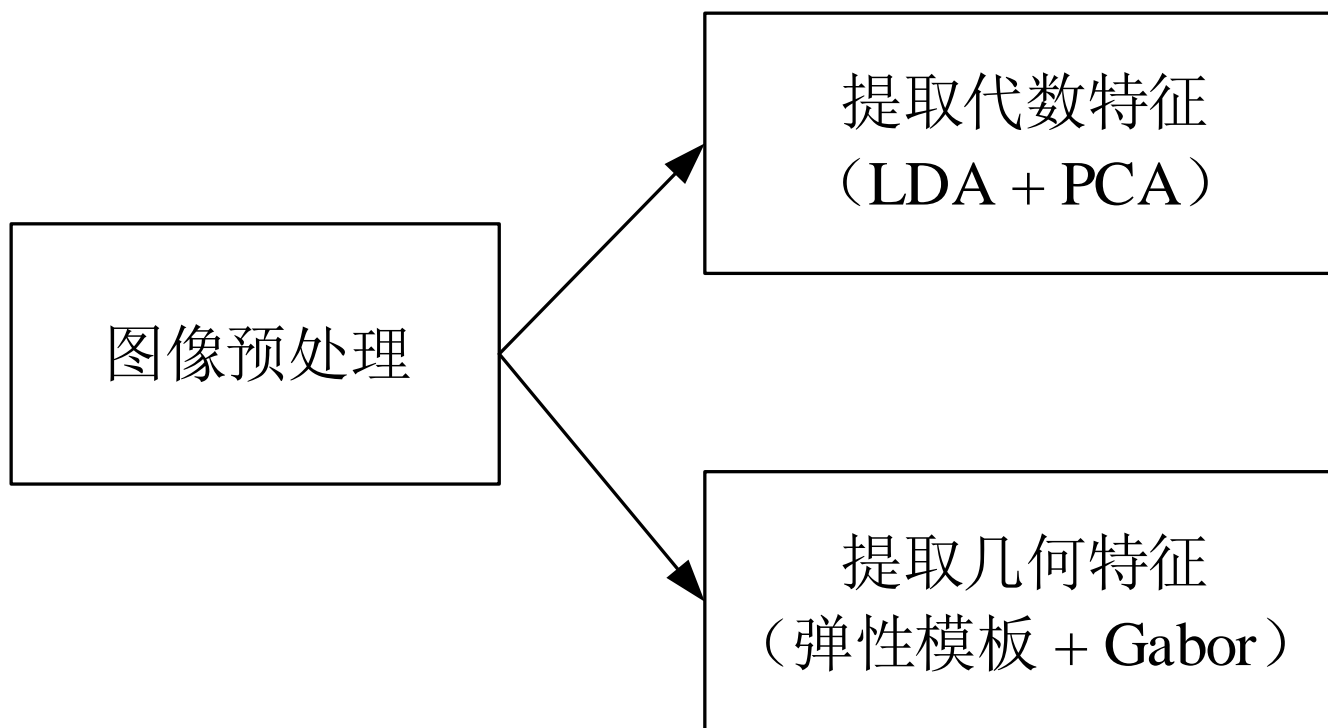
1.5 与作者相关的研究现状调查



2. 民族人脸识别总体方案

2. 民族人脸识别总体方案

- 本文做的主要工作：



2.1 图像预处理

- 1) 图像预处理

图像预处理分别采用了灰度变换（灰度均衡化，去除背景）和几何变换（尺寸归一化，校正姿态）

注意：为便于采集人脸几何特征，本文将左右眼宽平均值作为归一化基向量，对图像进行等比例变换（原因：眼睛的眼宽差异相对方差最小。图像经过归一化之后，可以提高数据质量，相应地提高分类算法识别效能）

2.2 提取代数特征

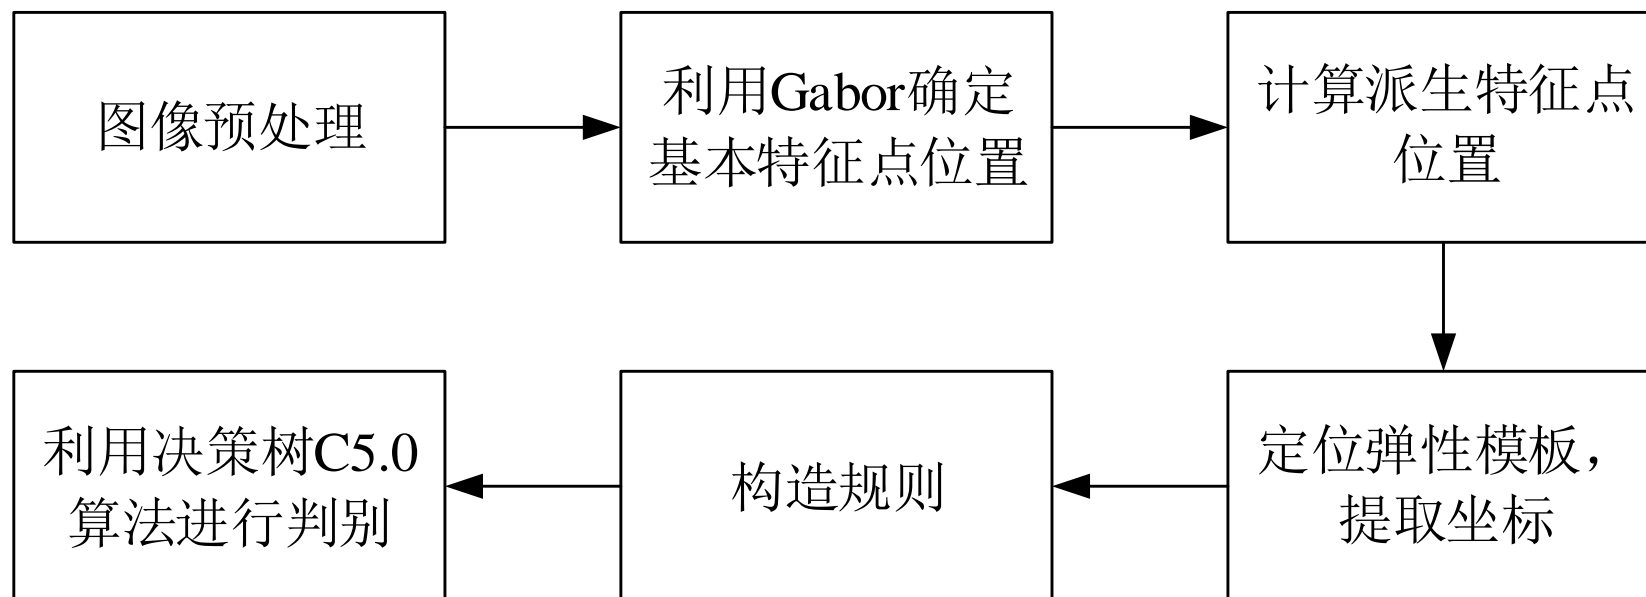
- 2) 代数特征提取

LDA方法可从人脸图片信息选择出散布于类内的正交向量，并将其作为人脸代数特征的特征向量

LDA算法思路在下一章分析，这里只需知道它的作用就够了

2.3 几何特征提取与识别

- 几何特征算法总体思想



2.3 几何特征提取与识别

- 3) 几何特征提取

通常包括面部主要特征点的位置以及指定点间的欧式距离或曲率、角度等

由这些特征便可以得到描述每张脸的特征矢量，将各民族人脸用一组几何特征矢量来表示


2.3 几何特征提取与识别

人类学相关研究表明，少数民族具有很多独特的面部特征，比如眉长轴和眼长轴及其之间夹角（眉长轴为眉毛最低点的连线，眼长轴为眼内外眦间的连线，例如蒙、藏族多为平行或外相交，维吾尔族多为平行或内相交）

同时，不同民族之间侧面人脸中的鼻根高度、位置和形状存在显著差异

2.3 几何特征提取与识别

比如下面的示意图，观察眉长轴，左边为维吾尔族人脸示意图，右边为蒙古族人脸示意图



2.3 几何特征提取与识别

- 下标描述了藏族、维吾尔族和壮族的人脸拓扑结构

民族	面部特征
藏族	<p>眼睛：眼裂开度中等趋窄，多数人显示内眦褶</p> <p>鼻子：鼻梁较直、细楞，鼻根高度大，鼻根凹小且靠近眉间</p> <p>嘴唇：中等唇厚，唇形稍凸：上红唇多数为中等厚，下红唇比上红唇厚</p> <p>面型：面部多呈长梭型及长梯型</p> <p>头发：发质较硬；发黑直，间有波型及卷曲型</p> <p>耳朵：1 / 3 耳壳上显示达尔文结节，耳垂形状多为圆形，部分为方形，三角形甚少</p> <p>肤色：黄褐、黑褐或古铜色</p>

2.3 几何特征提取与识别

民族	面部特征
维吾尔族	<p>眼睛：眼裂开度中等，眼为楔形结构，上睑皱褶明显，睑沿宽，睑裂大</p> <p>鼻子：鼻根中等偏高，鼻尖高</p> <p>嘴唇：上唇皮肤部高度多为中等和偏高，红唇多为中唇和唇</p> <p>面型：卵圆形</p> <p>头发：发黑间有黑褐色，头发有直、波、卷曲三型</p> <p>耳朵：大多有达尔文节，耳垂多为圆形和方形</p> <p>肤色：肤色呈黄、白或棕褐。</p>

2.3 几何特征提取与识别


民族	面部特征
壮族	<p>眼睛：眼裂开度较宽，蒙古褶较弱育，多数呈微显型</p> <p>鼻子：鼻梁硬骨部稍下凹软骨部略上凸</p> <p>嘴唇：上唇皮肤部一般为中等高度，明显前凸；红唇厚度数为中等偏厚</p> <p>面型：中面型和阔面型为主</p> <p>头发：发形直、发色黑</p> <p>耳朵：耳壳上多数没有达尔文结节，耳垂向下，悬挂成舌状，即圆形耳垂</p>

2.3 几何特征提取与识别

- 根据上述人脸拓扑结构，论文采用弹性模板和Gabor小波来提取几何特征。首先，什么是弹性模板？
- 弹性模板，就是在人脸上标注若干关键点，这些点具有各自的几何含义（比如点 p_1 表示左外眼角，点 p_2 表示左内眼角...），在不同的人脸上，这些点的具体像素坐标会有不同，看起来就像有弹性一样


2.3 几何特征提取与识别

- 下图是一个几何模板的示例



2.3 几何特征提取与识别

- 论文采用的弹性模板示意图，左边为维吾尔族人脸，中间为藏族人脸，右边为蒙古族人脸



2.3 几何特征提取与识别

- 当然，也有研究者认为，弹性模板中的点并非都具有“弹性”，可能也存在一些点始终是固定的（张海龙.基于弹性模板的民族面部特征研究[D].东北大学.2010）

2.3 几何特征提取与识别

- 这里有一个问题：几何特征点的基础是各个关键点，那么这些关键点是如何提取的？
- 本文没有直接说明，但来自第三作者刘慧的硕士学位论文中给出了一种方法：积分投影法

2.3 几何特征提取与识别

- 积分投影法（Integral Projection Function, IPF）的基本思想是：对正面人脸图像进行水平积分投影，然后利用曲线的极值来定位各特征点
- 根据图像某些方向上的投影分布特征来进行检测，本质上是一种统计方法
- 积分投影法主要有水平投影和垂直投影

2.3 几何特征提取与识别

- 设 $G(x, y)$ 表示图像 (x, y) 处的灰度值，在图像 $[y_1, y_2]$ 和 $[x_1, x_2]$ 区域的水平积分 $M_h(x)$ 表示为：

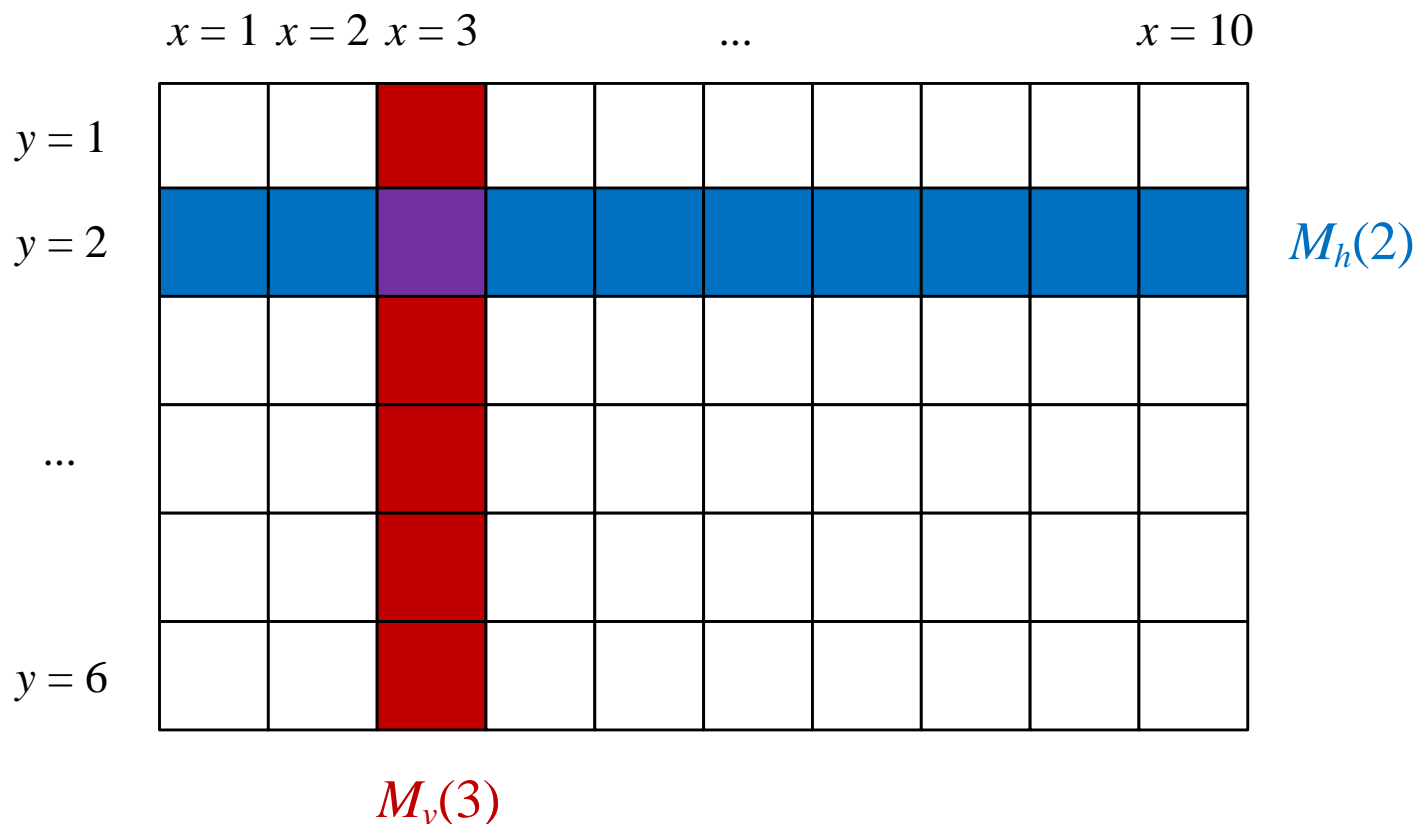
$$M_h(y) = \frac{1}{x_2 - x_1} \sum_{x_1}^{x_2} G(x, y)$$

- 垂直积分表示为：

$$M_v(x) = \frac{1}{y_2 - y_1} \sum_{y_1}^{y_2} G(x, y)$$

2.3 几何特征提取与识别

- 水平积分和垂直积分示意图



2.3 几何特征提取与识别

- 对每一行（或者每一列）提取了积分之后，可以得到相应的函数曲线，如下图所示：





图 4.9 (a) 垂直投影曲线



(b) 水平投影曲线

2.3 几何特征提取与识别

- 得到了函数曲线之后，通过梯度计算来找到曲线的极值点（波峰和波谷），进而对特征点进行定位
- 很多个特征点计算出来之后，就得到了人脸弹性模板

2.3 几何特征提取与识别

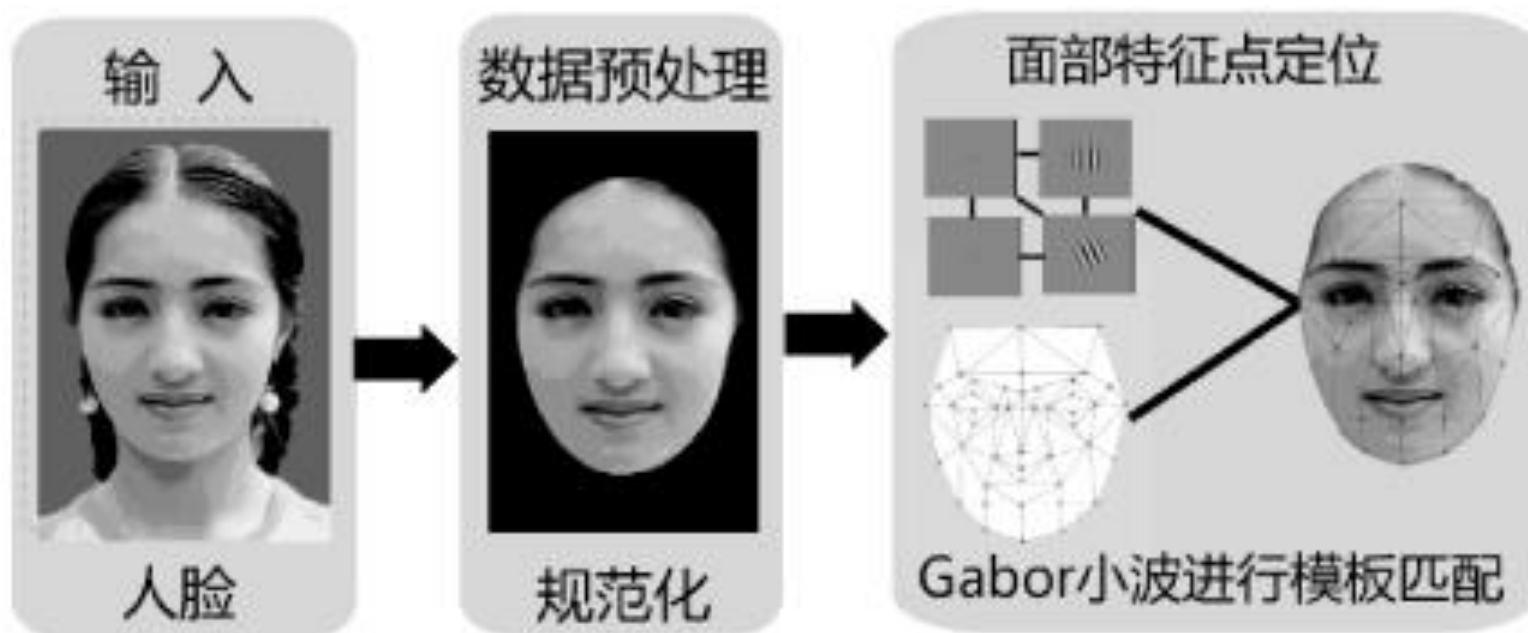
- 另一个问题，已经能够得到弹性模板，为什么还需要Gabor小波？
- 它可以在弹性模板的基础上进行Gabor特征提取，形成人脸属性标号图，最后民族人脸识别的过程就转换为各民族人脸标号图之间的比较（援引文献《民族面部特征提取及其识别算法研究_刘慧》P49），关于标号图，后续会有详细介绍

2.3 几何特征提取与识别

- 对于本文而言，利用Gabor小波提取图像不同区域的不同频率成分和方向的纹理信息
- 关于Gabor的详细信息会在PPT后续章节介绍，本节仅阐述上层业务逻辑

2.3 几何特征提取与识别

- 论文对Gabor的应用示意图：




2.3 几何特征提取与识别

- 论文的原话：“本文建立人脸的特征点和弹性模板的对应部位的特征之间的联系，抽取能表达人脸各器官拓扑关系的几何特征”
- 论文的原话：“利用Gabor小波通过弹性束图匹配来确定图3所示基本特征点的位置、基本特征点的选取（如眉、眼睛、鼻子、嘴巴以及脸部轮廓等）。”
（论文所述的图3见下页）

2.3 几何特征提取与识别

- 即：利用Gabor来定位特征点



2.3 几何特征提取与识别

- 定位了特征点后（包括基本特征点和派生特征点）
- 派生特征点是根据基本特征点算出来的，比如求中点等方法

2.3 几何特征提取与识别

- 得到了特征点后，就得到了一个弹性模板（每个点都用几何参数表示）
- 每一张脸都对应一组这样的参数，利用这些数据进行训练，可以得到分类规则

2.3 几何特征提取与识别

- 论文中展示的分类规则树截图：

规则 1 规则准确率 90% 鼻宽 ≤ 0.589 [类别:藏族] \Rightarrow 藏族

鼻宽 > 0.589 [类别:维吾尔族]

嘴角到同侧内眼角 ≤ 2.030 [类别:壮族] \Rightarrow 壮族

嘴角到同侧内眼角 > 2.030 [类别:维吾尔族]

鼻翼处脸宽 ≤ 4.462 [类别:维吾尔族]

嘴宽 ≤ 1.481 [类别:藏族] \Rightarrow 藏族

嘴宽 > 1.481 [类别:维吾尔族] \Rightarrow 维吾尔族

鼻翼处脸宽 > 4.462 [类别:壮族] \Rightarrow 壮族

规则 2 规则准确率 72.59%

下巴到嘴角 ≤ 1.526 [类别:壮族]

下巴到鼻尖 ≤ 1.913 [类别:藏族] \Rightarrow 藏族

下巴到鼻尖 > 1.913 [类别:壮族] \Rightarrow 壮族

下巴到嘴角 > 1.526 [类别:维吾尔族]

鼻翼处脸宽 ≤ 4.220 [类别:维吾尔族] \Rightarrow 维吾尔族

鼻翼处脸宽 > 4.220 [类别:藏族] \Rightarrow 藏族

规则 3 规则准确率 87.18%

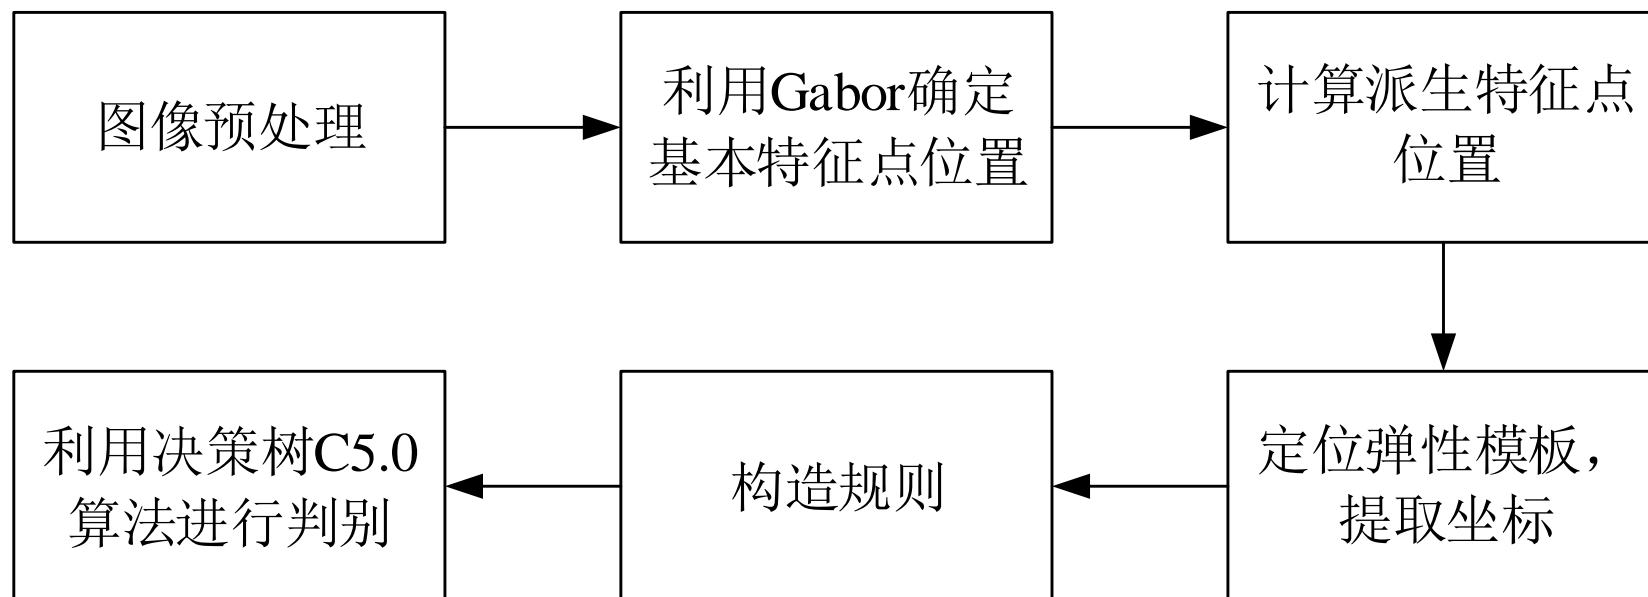
2.3 几何特征提取与识别

- 得到了规则树之后，就可以用这棵树对测试样本进行预测

	藏族	维吾尔族	壮族
藏族测试集	0.885714	0.071429	0.042857
维吾尔族测试集	0.071429	0.900000	0.028571
壮族测试集	0.042857	0.014286	0.942857

2.3 几何特征提取与识别

- 最后回顾一下几何特征抽取与识别的过程





3. 二元LDA线性判别分析

3.1 二元LDA问题引入

- 通常情况下，待匹配人脸要和人脸库内的多张人脸匹配，所以这是一个多分类的情况。出于简单考虑，可以先介绍二类的情况然后拓展到多类。
- 假设有二维平面上的两个点集 $\{X_1\}$ 和 $\{X_2\}$ ，它们的分布如下图所示（分别以蓝点和红点表示数据）：

3.1 二元LDA问题引入




3.1 二元LDA问题引入

- 原有数据是散布在平面上的二维数据，如果想用一维的量（比如到圆点的距离）来合理的表示而且区分开这些数据，该怎么办呢？
- 一种有效的方法是找到一个合适的向量 \mathbf{w} 进行投影，LDA算法约定这个向量是经过原点的

3.1 二元LDA问题引入

- 看刚才这张图片，我们假设有两种投影方案（即有两个 \mathbf{w} ，两者都是过原点的直线），似乎右边的方案更好一些
- Question: 如何让计算机找到这样一个最优的投影向量？



3.1 二元LDA问题引入

- 首先定义问题:

给定 N 个样本, 它们都是 d 维:

$$x^{(i)} \{x_1^{(i)}, x_2^{(i)}, \dots, x_d^{(i)}\}$$

其中有 N_1 个样本属于类别 ω_1 , 另外 N_2 个样本属于类别 ω_2

3.1 二元LDA问题引入


- 通俗地讲，现在我们觉得原始特征数太多，想将 d 维特征降到只有一维，而又要保证类别能够“清晰地反映在低维数据上，也就是这一维就能决定每个样例的类别
- 维数降到只有一维，那会是什么？它代表一种距离

3.1 二元LDA问题引入

- 假设我们找到的这个最优向量为 \mathbf{w} ，那么样例 x （ d 维）到 \mathbf{w} 上的投影可以用下式来计算

$$y = \mathbf{w}^T x \quad (1)$$

这里的 y 就是 x 投影到直线上的点到原点的距离，参考右图



3.2 投影

- 首先计算每一类训练样本的均值（即中心点）

$$\mu_i = \frac{1}{N_i} \sum_{x \in \omega_i} x \quad (2)$$

- 样本投影到 \mathbf{w} 上的均值为

$$\tilde{\mu}_i = \frac{1}{N_i} \sum_{y \in \omega_i} y = \frac{1}{N_i} \sum_{y \in \omega_i} \mathbf{w}^T x = \mathbf{w}^T \mu_i \quad (3)$$

3.3 定义求解标准

- 最佳投影向量 \mathbf{w} 的标准：1、不同的分类得到的投影点要尽量分开；2、同一个分类投影后得到的点要尽量聚合
- 据此定义 $|\widetilde{\mu}_1 - \widetilde{\mu}_2|$ ，它表示不同类别投影中心的距离

$$|\widetilde{\mu}_1 - \widetilde{\mu}_2| = |\mathbf{w}^T(\mu_1 - \mu_2)| \quad (4)$$

显然， $|\widetilde{\mu}_1 - \widetilde{\mu}_2|$ 越大越好

3.3 定义求解标准

- 又定义投影后的散列值（scatter） \tilde{s}_i^2 ，即对投影后的类求散列值

$$\tilde{s}_i^2 = \sum_{y \in \omega_i} (y - \tilde{\mu}_i)^2 \quad (5)$$

跟我们熟悉的方差相比，散列值只是没有除以样本数量。它的几何意义是样本点的密集程度，值越大，越分散，反之，越集中。

3.3 定义求解标准

分子：两类中心距离

- 由上述(4)式和(5)式，得到最终希望的求解标准度量公式：

$$J(\mathbf{w}) = \frac{|\widetilde{\mu}_1 - \widetilde{\mu}_2|^2}{\widetilde{s}_1^2 + \widetilde{s}_2^2} \quad (6)$$

分母：每个类自己的散列度加和

即

$$\max_{\mathbf{w}} J(\mathbf{w}) = \max_{\mathbf{w}} \frac{|\widetilde{\mu}_1 - \widetilde{\mu}_2|^2}{\widetilde{s}_1^2 + \widetilde{s}_2^2} \quad (7)$$

3.3 定义求解标准

- 以 \tilde{s}_1^2 为例，将(6)式中的 \tilde{s}_1^2 展开，得

$$\begin{aligned}\tilde{s}_1^2 &= \sum_{y \in \omega_i} (y - \widetilde{\mu}_1)^2 = \sum_{y \in \omega_i} (\mathbf{w}^T x - \mathbf{w}^T \mu_1)^2 \\ &= \sum_{y \in \omega_i} \mathbf{w}^T (x - \mu_1)(x - \mu_1)^T \mathbf{w}\end{aligned}$$

(8)

3.3 定义求解标准

- 同理，得到：

$$\left\{ \begin{array}{l} \tilde{s}_1^2 = \sum_{y \in \omega_1} \mathbf{w}^T (x - \mu_1)(x - \mu_1)^T \mathbf{w} \quad (9) \\ \tilde{s}_2^2 = \sum_{y \in \omega_2} \mathbf{w}^T (x - \mu_2)(x - \mu_2)^T \mathbf{w} \quad (10) \end{array} \right.$$

3.3 定义求解标准

- 即

$$\begin{aligned}\tilde{s}_i^2 &= \sum_{y \in \omega_i} \mathbf{w}^T (x - \mu_i)(x - \mu_i)^T \mathbf{w} \\ &= \mathbf{w}^T \sum_{y \in \omega_i} (x - \mu_i)(x - \mu_i)^T \mathbf{w}\end{aligned}\tag{11}$$

3.3 定义求解标准

- 在上述(11)式中，令中间红颜色的部分为

$$\sum_{y \in \omega_i} (x - \mu_i)(x - \mu_i)^T = S_i \quad (12)$$

跟协方差矩阵相比，它仅仅没有除以样本数目，这样的矩阵 S_i 称为散列矩阵

3.3 定义求解标准

- 定义类内散列矩阵（Within-class scatter matrix） S_w

$$S_w = S_1 + S_2$$

$$= \sum_{y \in \omega_1} (x - \mu_1)(x - \mu_1)^T + \sum_{y \in \omega_2} (x - \mu_2)(x - \mu_2)^T$$

(13)

3.3 定义求解标准

- 于是，上述(11)式可以变为

$$\tilde{s}_i^2 = \mathbf{w}^T \mathbf{S}_i \mathbf{w} \quad (14)$$

- 用替换法，还可以得到

$$\begin{aligned} \tilde{s}_1^2 + \tilde{s}_2^2 &= \mathbf{w}^T \mathbf{S}_1 \mathbf{w} + \mathbf{w}^T \mathbf{S}_2 \mathbf{w} = \mathbf{w}^T (\mathbf{S}_1 \mathbf{w} + \mathbf{S}_2 \mathbf{w}) \\ &= \mathbf{w}^T [(\mathbf{S}_1 + \mathbf{S}_1) \mathbf{w}] = \mathbf{w}^T (\mathbf{S}_1 + \mathbf{S}_1) \mathbf{w} = \mathbf{w}^T \mathbf{S}_W \mathbf{w} \quad (15) \end{aligned}$$

3.3 定义求解标准

- 这样，(6)式 $J(\mathbf{w}) = \frac{|\widetilde{\mu}_1 - \widetilde{\mu}_2|^2}{\widetilde{s}_1^2 + \widetilde{s}_2^2}$ 中的分母部分就进行了一次转换，下面观察分子

- 对分子进行展开，有

$$\begin{aligned} |\widetilde{\mu}_1 - \widetilde{\mu}_2|^2 &= (\widetilde{\mu}_1 - \widetilde{\mu}_2)^2 = (\mathbf{w}^T \mu_1 - \mathbf{w}^T \mu_2)^2 \\ &= \mathbf{w}^T \underbrace{(\mu_1 - \mu_2)(\mu_1 - \mu_2)^T}_{S_B} \mathbf{w} = \mathbf{w}^T S_B \mathbf{w} \quad (16) \end{aligned}$$

S_B 即类间散列矩阵（Between-class scatter matrix）

3.3 定义求解标准

- (16)式中产生了一个小式子(16.1)

$$S_B = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T \quad (16.1)$$

3.3 定义求解标准

- 关于(16)式的推导

$$\begin{aligned} & \mathbf{w}^T (\mu_1 - \mu_2) (\mu_1 - \mu_2)^T \mathbf{w} \\ &= (\mathbf{w}^T \mu_1 - \mathbf{w}^T \mu_2) (\mu_1^T \mathbf{w} - \mu_2^T \mathbf{w}) \\ &= (\mathbf{w}^T \mu_1 - \mathbf{w}^T \mu_2) (\mathbf{w}^T \mu_1 - \mathbf{w}^T \mu_2)^T \\ &= (\mathbf{w}^T \mu_1 - \mathbf{w}^T \mu_2)^2 \end{aligned}$$

其中，对于矩阵 A ， A^2 视为 AA^T

结论1:

$$\mathbf{w}^T (\mu_1 - \mu_2) (\mu_1 - \mu_2)^T \mathbf{w} = (\mathbf{w}^T \mu_1 - \mathbf{w}^T \mu_2)^2$$

3.3 定义求解标准

类间散列矩阵

- 这样，(6)式可以表示为

$$J(\mathbf{w}) = \frac{|\widetilde{\mu}_1 - \widetilde{\mu}_2|^2}{\widetilde{s}_1^2 + \widetilde{s}_2^2} = \frac{\mathbf{w}^T \mathbf{S}_B \mathbf{w}}{\mathbf{w}^T \mathbf{S}_W \mathbf{w}} \quad (17)$$

类内散列矩阵

对(17)式的分母进行归一化，得到约束条件

$$\|\mathbf{w}^T \mathbf{S}_W \mathbf{w}\| = 1 \quad (18)$$

3.4 拉格朗日

- 利用 $J(\mathbf{w})$ 以及约束条件构造拉格朗日表达式

$$c(\mathbf{w}) = \mathbf{w}^T \mathbf{S}_B \mathbf{w} - \lambda(\mathbf{w}^T \mathbf{S}_W \mathbf{w} - 1) \quad (19)$$

- 对 \mathbf{w} 求偏导，并令其为零，得

$$\frac{\partial c}{\partial \mathbf{w}} = 2\mathbf{S}_B \mathbf{w} - 2\lambda \mathbf{S}_W \mathbf{w} = 0 \Rightarrow \mathbf{S}_B \mathbf{w} = \lambda \mathbf{S}_W \mathbf{w} \quad (20)$$

这里面用到了矩阵微积分，求导时可以简单把 $\mathbf{w}^T \mathbf{S}_W \mathbf{w}$ 当作 $\mathbf{S}_W \mathbf{w}^2$ 来看待

3.4 拉格朗日

- 观察(20)式, $S_B \mathbf{w} = \lambda S_W \mathbf{w}$, 如果 S_W 可逆, 那么可以在求导结果两边都乘以 S_W^{-1} , 得到

$$S_W^{-1} S_B \mathbf{w} = \lambda S_W^{-1} S_W \mathbf{w} \quad (21)$$

进而

$$S_W^{-1} S_B \mathbf{w} = \lambda \mathbf{w} \quad (22)$$

不难看出, 此时的 \mathbf{w} 就是特征向量, λ 就是对应的特征值

3.4 拉格朗日

- 在式(22)中， S_W^{-1} 和 S_B 均可以求出（见(13)式和(16)式），因此特征向量 \mathbf{w} 和对应的特征值 λ 也能够求出
- 附：回顾(13)式和(16)式

$$S_W = S_1 + S_2 \quad (13)$$

$$\begin{aligned} |\widetilde{\mu}_1 - \widetilde{\mu}_2|^2 &= (\widetilde{\mu}_1 - \widetilde{\mu}_2)^2 = (\mathbf{w}^T \mu_1 - \mathbf{w}^T \mu_2)^2 \\ &= \mathbf{w}^T (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T \mathbf{w} = \mathbf{w}^T S_B \mathbf{w} \quad (16) \end{aligned}$$

3.4 拉格朗日

- 上述公式(22) $S_W^{-1} S_B \mathbf{w} = \lambda \mathbf{w}$ 就是传统的做法，但不推荐，因为对于LDA问题，还有更快的做法
- 现在来看另一种求解 \mathbf{w} 和 λ 的思路（Fisher提出来的）

3.5 Fisher的求解思路

- 再一次观察，由(16.1)式中的定义

$$\mathbf{S}_B = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T$$

- 那么(22)式中的

$$\mathbf{S}_B \mathbf{w} = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T \mathbf{w} \quad (23)$$

3.5 Fisher的求解思路

- 由(23), 可以将(22) $S_W^{-1} S_B \mathbf{w} = \lambda \mathbf{w}$ 改写为

$$S_W^{-1} (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T \mathbf{w} = \lambda \mathbf{w} \quad (24)$$

3.5 Fisher的求解思路

- (24)式中部分项可以“约掉”，得到

$$S_W^{-1}(\mu_1 - \mu_2)(\mu_1 - \mu_2)^T \mathbf{w} = \lambda \mathbf{w} \quad (24)$$

$$\Rightarrow S_W^{-1}(\mu_1 - \mu_2) = \mathbf{w} \quad (25)$$

- Question: 为什么这里可以如此“约掉”？

3.5 Fisher的求解思路

- 现在来分析为什么可以如此“约掉”
- 看前面的(16.1)式 $S_B = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T$ ，不难发现， $S_B \mathbf{w}$ ，即 $(\mu_1 - \mu_2)(\mu_1 - \mu_2)^T \mathbf{w}$ ，与 $\mu_1 - \mu_2$ 的方向总是一致的
- (24)式： $S_W^{-1} (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T \mathbf{w} = \lambda \mathbf{w}$ 的左边可以写成 $S_W^{-1} (\mu_1 - \mu_2)$

Notice: 蓝颜色的部分与紫颜色的部分方向一致

3.5 Fisher的求解思路

- 再观察(24)式: $S_W^{-1}(\mu_1 - \mu_2)(\mu_1 - \mu_2)^T \mathbf{w} = \lambda \mathbf{w}$
- 看右边 $\lambda \mathbf{w}$, 它的方向与 \mathbf{w} 一致, 因此可以写为 \mathbf{w}
- 这样, (24)式就变为

$$S_W^{-1}(\mu_1 - \mu_2) = \mathbf{w} \quad (25)$$

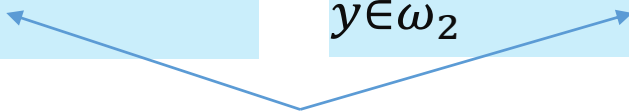
3.5 Fisher的求解思路

根据(25)式，可得

$$\mathbf{w} = S_W^{-1}(\mu_1 - \mu_2) \quad (26)$$

其中，

$$S_W = S_1 + S_2 = S_i$$


$$= \sum_{y \in \omega_1} (x - \mu_1)(x - \mu_1)^T + \sum_{y \in \omega_2} (x - \mu_2)(x - \mu_2)^T$$


跟协方差矩阵相比，它仅仅没有除以样本数目，这样的矩阵 S_i 称为散列矩阵

3.5 Fisher的求解思路

- 综上所述，根据Fisher的思想，要求出 \mathbf{w} ，只需要求出原始样本的均值和方差就可以了
- 下面感性理解为什么Fisher可以这么做？

3.5 Fisher的求解思路



- 前面说过，我们要找的投影向量 \mathbf{w} ，相当于一个射线
- 对于这条射线，我们并不关心它的大小，我们只关心它的方向

4. 多元LDA线性判别分析

4.1 多元LDA问题引入

- 前面描述的只是两个类情况下的LDA算法，在实际人脸识别中，如果有 C 个人的样本，那么类别的数量一定是 C ， C 肯定不止两个

4.1 多元LDA问题引入

- 另一方面，之前进行二元LDA时，我们原有的数据是二维的
- 我们希望找到一个合适的向量 \mathbf{w} 进行投影，将原有的二维数据用一维的量（比如到圆点的距离）来表示而且区分开它们
- 而现在类别多了，降到一维可能不够用

4.1 多元LDA问题引入


- 多元LDA问题：数据有 C 个类别，需要 K 维向量（或者叫做基向量）来进行投影
- 这 K 维向量表示为 $W = [\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_K]$ ，将样本点在这 K 维向量投影后结果表示为 $[\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_K]$ ，满足

$$y_i = \mathbf{w}_i^T x \quad (27)$$


$$y = W^T x \quad (28)$$

4.2 概念定义

- 为了像上节一样度量 $J(\mathbf{w})$ ，我们打算仍然从类间散列度和类内散列度来考虑。
- 当样本是二维时，我们从几何意义上考虑：




4.2 概念定义



- 其中 μ_i 和与 S_W 跟上节的意义一样，比如 S_{W1} 是类别1里的样本点相对于该类中心点 μ_1 的散列程度。（此处的 S_{W1} 应该就是一节中的 S_i ）

4.2 概念定义



- S_{B1} 变成类别1中心点相对于所有样本中心点 μ 的协方差矩阵，即类别1相对于 μ 的散列程度。

4.2 概念定义

- 某类样本的类内散列矩阵 S_{W_i} ，它的维度是 $n \times n$

$$S_{W_i} = \sum_{x \in \omega_i} (x - \mu_i)(x - \mu_i)^T \quad (29)$$

- 全体样本类内散列矩阵 S_W

$$S_W = \sum_{i=1}^C S_{W_i} = \sum_{i=1}^C \sum_{x \in \omega_i} (x - \mu_i)(x - \mu_i)^T \quad (30)$$

4.2 概念定义

- 所有样本的中心 (N_i 代表类别*i*内*x*的个数)

$$\mu = \frac{1}{N} \sum_{\forall x} x = \frac{1}{N} \sum_{\forall x} N_i \mu_i \quad (31)$$

- 原始样本类间散列矩阵加和 S_B (N_i 代表类别*i*内*x*的个数)，注意多元情况下 S_B 的概念与二元情况下的不同

$$S_B = \sum_{i=1}^C N_i (\mu_i - \mu)(\mu_i - \mu)^T \quad (32)$$

4.2 概念定义

- 从(32)式可以看到，在多元情况下， S_B 的计算发生了改变，对比二元情况下的(16)式

$$S_{B(\text{二元})} = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T \quad (16)$$

$$S_{B(\text{多元})} = \sum_{i=1}^C N_i (\mu_i - \mu)(\mu_i - \mu)^T \quad (32)$$

4.2 概念定义

- 对比上述(16)式和(32)式，二元情况下 S_B 度量的是两个均值点的散列情况
- 多元情况下 S_B 度量的是每类均值点相对于样本中心的散列情况

4.2 概念定义

- 总结一下概念的变化

	二元LDA	多元LDA
μ_i	某类样本中心点	某类样本中心点
S_{W_i}	类内散列矩阵	类内散列矩阵
S_B	(S_B) 类间散列矩阵	(S_{B_i}) 类间散列矩阵和二元情况下有较大不同, 它代表的是每个类别到 μ 距离的加和

4.2 概念定义

- 某一类样本投影后的均值

$$\tilde{\mu}_i = \frac{1}{N_i} \sum_{y \in \omega_i} y = \frac{1}{N_i} \sum_{x \in \omega_i} W^T x \quad (33)$$

- 所有样本投影后的均值

$$\tilde{\mu} = \frac{1}{N} \sum_{\forall y} y = \frac{1}{N} \sum_{\forall x} W^T x \quad (34)$$

4.2 概念定义

- 投影后的类内散列矩阵 \widetilde{S}_W

$$\begin{aligned}\widetilde{S}_W &= \sum_{i=1}^C \sum_{y \in \omega_i} (y - \tilde{\mu}_i)(y - \tilde{\mu}_i)^T \\ &= \sum_{i=1}^C \sum_{x \in \omega_i} (W^T x - \tilde{\mu}_i)(W^T x - \tilde{\mu}_i)^T\end{aligned}\tag{35}$$

4.2 概念定义

- 与前述(30)式比较

$$S_W = \sum_{i=1}^C \sum_{x \in \omega_i} (x - \mu_i)(x - \mu_i)^T \quad (30)$$

$$\widetilde{S}_W = \sum_{i=1}^C \sum_{x \in \omega_i} (W^T x - \widetilde{\mu}_i)(W^T x - \widetilde{\mu}_i)^T \quad (35)$$

4.2 概念定义

- 投影后的类间散列矩阵 \widetilde{S}_B

$$\widetilde{S}_B = \sum_{i=1}^c N_i (\tilde{\mu}_i - \tilde{\mu})(\tilde{\mu}_i - \tilde{\mu})^T \quad (36)$$

其中， N_i 代表类别*i*内*x*的个数

$\tilde{\mu}_i$ 代表某一类样本投影后的均值

$\tilde{\mu}$ 代表所有样本投影后的均值

4.2 概念定义

- 与前述(32)式比较

$$S_B = \sum_{i=1}^C N_i (\mu_i - \mu)(\mu_i - \mu)^T \quad (32)$$

$$\widetilde{S}_B = \sum_{i=1}^C N_i (\tilde{\mu}_i - \tilde{\mu})(\tilde{\mu}_i - \tilde{\mu})^T \quad (36)$$

4.2 概念定义

- 综合各个投影向量 \mathbf{w} 上的 \widetilde{S}_W （投影后的类内散列矩阵）和 \widetilde{S}_B （投影后的类间散列矩阵），更新这两个参数，得到


$$\widetilde{S}_W = W^T S_W W \quad (37)$$

$$\widetilde{S}_B = W^T S_B W \quad (38)$$

其中的推导见下页

4.2 概念定义

蓝色部分参考关于(16)式的推导及其结论



- 现在推导(37)式

$$\begin{aligned} W^T S_W W &= W^T \sum_{i=1}^C \sum_{x \in \omega_i} (x - \mu_i)(x - \mu_i)^T W \\ &= \sum_{i=1}^C \sum_{x \in \omega_i} W^T (x - \mu_i)(x - \mu_i)^T W = \sum_{i=1}^C \sum_{x \in \omega_i} (W^T x - W^T \mu_i)^2 \\ &= \sum_{i=1}^C \sum_{x \in \omega_i} (W^T x - \tilde{\mu}_i)^2 = \sum_{i=1}^C \sum_{x \in \omega_i} (W^T x - \tilde{\mu}_i)(W^T x - \tilde{\mu}_i)^T = \widetilde{S}_W \end{aligned}$$

4.2 概念定义

- (38)式推导同上，此处略
- 经过推导后，现在我们完全能够确认(37)和(38)式的合理性

4.3 求解标准

- 仿照二元LDA的求解标准(17)式，在多元情况下，根据前面推导过的(37)式和(38)式，定义

$$J(W) = \frac{|\widetilde{S}_B|}{|\widetilde{S}_W|} = \frac{|W^T \mathbf{S}_B W|}{|W^T \mathbf{S}_W W|} \quad (39)$$

投影后的类
间散列矩阵

投影后的类
内散列矩阵

- 但是，表达式中为什么会有 $|\quad|$ 的符号？答案是：行列式记号，后面详细解释

4.3 求解标准

- 将(17)式粘贴过来对照着看

$$J(\mathbf{w}) = \frac{|\widetilde{\mu}_1 - \widetilde{\mu}_2|^2}{\widetilde{s}_1^2 + \widetilde{s}_2^2} = \frac{\mathbf{w}^T \mathbf{S}_B \mathbf{w}}{\mathbf{w}^T \mathbf{S}_W \mathbf{w}} \quad (17)$$

二元LDA

$$J(W) = \frac{|\widetilde{\mathbf{S}}_B|}{|\widetilde{\mathbf{S}}_W|} = \frac{|W^T \mathbf{S}_B W|}{|W^T \mathbf{S}_W W|} \quad (39)$$

多元LDA

注意：(17)式中的 \mathbf{w} 是一个向量，(39)式中的 W 是一个矩阵，刚刚提到的 $|\quad|$ 符号问题是否与这种差异相关？

4.3 求解标准

- 关于(17)式的分子，我们回顾(16)式，可以肯定 $\mathbf{w}^T \mathbf{S}_B \mathbf{w}$ 的结果是一个标量

$$\begin{aligned} |\widetilde{\mu}_1 - \widetilde{\mu}_2|^2 &= (\widetilde{\mu}_1 - \widetilde{\mu}_2)^2 = (\mathbf{w}^T \mu_1 - \mathbf{w}^T \mu_2)^2 \\ &= \mathbf{w}^T (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T \mathbf{w} = \mathbf{w}^T \mathbf{S}_B \mathbf{w} \quad (16) \end{aligned}$$


- 关于(17)式的分母，我们回顾(15)式，可以肯定 $\widetilde{s}_1^2 + \widetilde{s}_2^2$ 的计算结果是一个标量

$$\begin{aligned} \widetilde{s}_1^2 + \widetilde{s}_2^2 &= \mathbf{w}^T \mathbf{S}_1 \mathbf{w} + \mathbf{w}^T \mathbf{S}_2 \mathbf{w} = \mathbf{w}^T (\mathbf{S}_1 \mathbf{w} + \mathbf{S}_2 \mathbf{w}) \\ &= \mathbf{w}^T [(\mathbf{S}_1 + \mathbf{S}_1) \mathbf{w}] = \mathbf{w}^T (\mathbf{S}_1 + \mathbf{S}_1) \mathbf{w} = \mathbf{w}^T \mathbf{S}_W \mathbf{w} \quad (15) \end{aligned}$$

4.3 求解标准

- 所以，(17)式的表达式实质上是两个标量相除，这也是二元LDA计算的特点

- 可是多元LDA就不一样了，看(39)式

$$J(W) = \frac{|\widetilde{S}_B|}{|\widetilde{S}_W|} = \frac{|W^T \textcolor{blue}{S}_B W|}{|W^T \textcolor{red}{S}_W W|} \quad (39)$$


分子和分母| |符号里面的内容都是矩阵，而矩阵不能直接做除法，因此我们需要引入某种机制，这里引入的是行列式（是否还存在其他办法尚不了解）

4.3 求解标准

- 理由1：要将矩阵变成实数，需要取行列式

下面是引用的网页资料截图

然而，最后的 $J(w)$ 的形式是

$$J(w) = \frac{|\widetilde{S_B}|}{|\widetilde{S_w}|} = \frac{|W^T S_B W|}{|W^T S_w W|} \quad (13)$$

由于得到的分子分母都是散列矩阵，**要将矩阵变成实数**，**需要取行列式**。又因为行列式的值实际上是矩阵特征值的积，一个特征值可以表示在该特征向量上的发散程度。因此我们使用行列式来计算。

4.3 求解标准

- 理由2：又因为行列式的值实际上是矩阵特征值的积，一个特征值可以表示在该特征向量上的发散程度。

下面是引用的网页截图

② 为什么矩阵的行列式等于他所有特征值的乘积

为什么矩阵的行列式等于他所有特征值的乘积

幽灵辉耀团3339 数学 2014-11-11



优质解答

下载作业帮App，拍照秒答

因为矩阵可以化成对角元素都是其特征值的对角矩阵,而行列式的值不变,对角矩阵的行列式就是对角元素相乘

lwblXYbd 2014-11-11

4.3 求解标准

- 经过上述推导和分析，我们已经能够确认前述(39)式的合理性

$$J(W) = \frac{|\widetilde{S}_B|}{|\widetilde{S}_W|} = \frac{|W^T \textcolor{blue}{S}_B W|}{|W^T \textcolor{red}{S}_W W|} \quad (39)$$

- 现在的问题是：求出 W 使 $J(W)$ 能够取得最大值

4.4 求解

- W 由下式最大特征值对应的特征向量组成

$$S_B \mathbf{w}_i = \lambda_i S_W \mathbf{w}_i \quad (40)$$

注意：关于为什么可以这么做，权威书籍说其中的证明比较复杂（包括《模式分类》和《模式识别与机器学习》），均没有给出过程，我们只需知道这么用就够了

4.4 求解

- 对上述(40)式 $S_B \mathbf{w}_i = \lambda_i S_W \mathbf{w}_i$ 求特征向量
- 首先，如果 S_W 是非奇异的，那么(40)式的求解实质上就是传统特征向量的求解，然而这么做其实并不方便，因为在对 S_W 求逆时要进行不必要的计算。相应地，我们可以将特征值作为下述(41)的根进行求解

4.4 求解

- 特征值可以看作是(41)式的根

$$|S_B - \lambda_i S_W| = 0 \quad (41)$$

- 得到了特征值，可以根据前述(40)式直接求出对应的特征向量

$$S_B \mathbf{w}_i = \lambda_i S_W \mathbf{w}_i \quad (40)$$

4.4 求解

- 回顾(32)式

$$S_B = \sum_{i=1}^C N_i (\mu_i - \mu)(\mu_i - \mu)^T \quad (32)$$

- 注意：由于 $(\mu_i - \mu)$ 秩为1，因此 S_B 的秩至多为 C
（矩阵的秩小于等于各个相加矩阵的秩的和）。由于知道了前 $C - 1$ 个 μ_i 后，最后一个 μ_C 可以有前面的 $C - 1$ 个 μ_i 线性表示，因此 S_B 的秩至多为 $C - 1$ 。那么特征向量最多有 $C - 1$ 个

汇报结束，谢谢大家！