

一种应用于人脸识别的超分辨率方法

夏苏娜, 马小虎

(苏州大学计算机科学与技术学院, 江苏 苏州 215006)

摘 要: 为提高局部保持投影(LPP)在人脸图像超分辨率中的适用性, 在 LPP 中引入典型相关分析(CCA), 提出一种相关性增强的局部保持投影方法(CELPP)。CELPP 用于提取高分辨率图像与低分辨率图像特征, 根据关系学习建立低分辨率图像特征与高分辨率图像特征之间的映射变换, 输入低分辨率图像, 通过 CELPP 特征提取和关系映射, 得到高分辨率图像, 并将其用于人脸识别。对人脸库 ORL 和 Yale 进行的实验结果表明, 该方法同时考虑了高分辨率图像与低分辨率图像的相似性及同类图像的局部结构性, 在基于人脸识别的超分辨率应用中优于 LPP 和 CCA。

关键词: 超分辨率; 局部保持投影; 典型相关分析; 相关性增强的局部保持投影; 关系学习

A Super-resolution Method Applied to Face Recognition

XIA Su-na, MA Xiao-hu

(School of Computer Science and Technology, Soochow University, Suzhou 215006, China)

【Abstract】 To enhance the applicability of Locality Preserving Projections(LPP) in super-resolution of face images, this paper proposes an improved method, Correlation Enhanced Locality Preserving Projection(CELPP), which introduces the method of Canonical Correlation Analyses(CCA) into LPP. CELPP is used for feature extraction, and relationship learning is used to build a bridge for the transformation of high resolution images and low resolution images. Entering low resolution images, through CELPP feature extraction and mapping transformation, the high resolution images are achieved and used for face recognition. Experimental results of ORL and Yale databases show that CELPP is better than LPP and CCA in super-resolution applications because CELPP considers the similarity of high resolution images and low resolution images, and the local structure of the same class images.

【Key words】 super-resolution; Locality Preserving Projections(LPP); Canonical Correlation Analysis(CCA); Correlation Enhanced Locality Preserving Projections(CELPP); relationship learning

DOI: 10.3969/j.issn.1000-3428.2014.04.041

1 概述

近年来, 由于人脸在视频监控、安全验证系统与人机交互系统等方面的巨大应用前景, 人脸识别领域的研究取得了迅速发展, 人脸识别技术已成为了当前模式识别和人工智能领域的一个研究热点。为确保在人脸图像采集设备较落后或外界环境因素影响较大的情况下, 仍能得到清晰的人脸图像, 基于人脸图像的超分辨率技术得到了广泛的应用。

基于人脸图像的超分辨率技术, 是指输入一幅或多幅低分辨率人脸图像, 通过相关算法, 得到一幅更为清晰的高分辨率人脸图像。图像的超分辨率技术最早是在 20 世纪 60 年代由 Harris J L 提出^[1], 而后文献[2]提出了虚幻脸(Hallucination Face)的思想, 并使基于人脸图像的超分辨率研究成为一个独立的研究领域, 从超分辨率技术中分离出来。近年来, 基于学习的方法是当前的研究热点。文

献[3]提出基于 Bayesian 的两步法构造虚幻脸, 文献[4-5]通过典型相关关系对其改进, 效果更为明显。由于高分辨率图像与低分辨率图像有着相似的几何结构和流形结构, 文献[6]提出的领域嵌入的方法和文献[7]的稀疏表示方法也有着重要的应用前景。

局部保持投影^[8](Locality Preserving Projections, LPP)是当前较为流行的一种人脸图像投影方法, 它不仅能够保持原始数据的非线性流形结构, 还避免了一般非线性方法难以获得新样本点低维投影这一缺陷。典型相关分析^[9](Canonical Correlation Analysis, CCA)是一种经典的向量之间相互依赖关系的多元数据处理方法, CCA 方法可以使得成对样本之间的相关性最大。

文献[10]提出一种基于 LPP 和 RBF 相结合的 LPH (Locality Preserving Hallucination)算法, 结果显示, LPH 有着较好的实验效果。本文将 CCA 引入到 LPP 中, 得到相关性增强的局部保持投影方法(Correlation Enhanced

作者简介: 夏苏娜(1988—), 女, 硕士研究生, 主研方向: 模式识别, 图像处理; 马小虎, 教授。

收稿日期: 2013-03-13 **修回日期:** 2013-05-06 **E-mail:** xiasuna@163.com

Locality Preserving Projections, CELPP)。CELPP 在构造样本近邻图时加入了类别信息, 当人脸的表情、神态发生变化时, 具有较强的鲁棒性。

2 相关算法

本文主要是将 CCA 引入 LPP 中, 使得新方法兼具了 LPP 与 CCA 的特性, 不仅能够保持人脸局部流形结构, 同时保证高分辨率图像与其对应的低分辨率图像之间的相关性最大。

2.1 局部保持投影

局部保持投影(LPP)是一种保留局部信息的方法, 与传统的 PCA(Principal Component Analysis)、LDA(Linear Discriminant Analysis)等不同, LPP 本质上是一种非线性方法, 因此, 将 LPP 用于特征提取时, 可以有效保持样本间的局部近邻关系, 解决了传统线性方法难以保持原始数据非线性流形结构的缺点。

已知 N 个中心化的样本 $X = \{x_1, x_2, \dots, x_N\} \in \mathbb{R}^{k \times N}$, 局部保持投影(LPP)的目标是寻找线性变换 W , 从而实现目标图像的特征提取:

$$y_i = W^T x_i, i = 1, 2, \dots, N \quad (1)$$

变换矩阵 W 可以通过下列目标函数得到:

$$\min(\sum_{ij} (y_i - y_j)^2 S_{ij}) \quad (2)$$

其中, S 为权值矩阵, 用于描述训练样本任意两点间的相似关系:

$$S_{ij} = \begin{cases} \exp(-\|x_i - x_j\|^2 / t) & x_i, x_j \text{ 同类} \\ 0 & \text{其他} \end{cases} \quad (3)$$

对式(2)代数变换, 该最小化问题可以转化为求解特征值问题:

$$XLX^T W = \lambda XD X^T W \quad (4)$$

其中, D 是对角矩阵, 对角线元素 $D_{ii} = \sum_j S_{ij}$; L 是拉普拉斯矩阵, $L = D - S$ 。

2.2 典型相关分析

文献[11]提出了典型相关分析(CCA)方法, 并使其成为一种研究随机向量相关性的经典方法, 该方法被广泛应用于超分辨率技术的研究中。

已知 N 对中心化的样本 $X_H \in \mathbb{R}^{k \times N}$ 和 $X_L \in \mathbb{R}^{l \times N}$, CCA 的目标是找到一对投影方向 U 、 V , 使得样本在这个方向上的投影分量 $Z_1 = U^T X_H$ 和 $Z_2 = V^T X_L$ 相关性最大。因此, CCA 的目标函数如下:

$$\max \rho = \frac{E[U^T X_H X_L^T V]}{\sqrt{E[U^T X_H X_H^T U] E[V^T X_L X_L^T V]}} = \frac{U^T C_{HL} V}{\sqrt{U^T C_{HH} U V^T C_{LL} V}} \quad (5)$$

其中, ρ 表示投影后变量的相关系数; C_{HL} 表示 X_H 和 X_L 的互协方差矩阵; C_{HH} 表示样本矩阵 X_H 的协方差矩阵; C_{LL} 表示样本矩阵 X_L 的协方差矩阵。

根据式(5), 投影方向 U 和 V 可以通过下列最优化问题来得到:

$$\begin{aligned} \max_{U, V} & U^T C_{XY} V \\ \text{s.t.} & U^T C_{XX} U + V^T C_{YY} V = 2 \end{aligned} \quad (6)$$

3 CELPP 在基于人脸图像超分辨率中的应用

3.1 增强相关性的局部保持投影

传统的局部保持投影能有效的保护人脸图像的流形结构, 但是当局部保持投影用于人脸图像的超分辨率研究时, 局部保持投影无法保证同一张人脸的高分辨率图像与其下采样后得到的低分辨率图像相关性最大。CELPP 在 LPP 的基础上, 引入了 CCA 的思想, 避免了 LPP 在超分辨率算法中的缺陷, 从而能更加有效地应用于人脸图像的超分辨率算法中。

已知 d 个人的 N 张高分辨率人脸图像 $I_H \in \mathbb{R}^{k \times N}$, 下采样后, 得到对应的 N 张低分辨率人脸图像 $I_L \in \mathbb{R}^{l \times N}$ 。假设均值图像分别为 $\mu_H \in \mathbb{R}^{k \times 1}$ 、 $\mu_L \in \mathbb{R}^{l \times 1}$, 将样本中心化, 得到训练数据 $X_H \in \mathbb{R}^{k \times N}$ 和 $X_L \in \mathbb{R}^{l \times N}$ 。

CELPP 结合了 CCA 以及 LPP 的特性, 其目标是分别为训练数据 X_H 和 X_L 找到最佳投影矩阵 U 和 V , 其目标函数如下所示:

$$\begin{aligned} \max_{U, V} & U^T C_{HL} V - \begin{bmatrix} U \\ V \end{bmatrix}^T \begin{bmatrix} X_H \\ X_L \end{bmatrix} (D - S) \begin{bmatrix} X_H \\ X_L \end{bmatrix} \begin{bmatrix} U \\ V \end{bmatrix} \\ \text{s.t.} & U^T C_{HH} U + V^T C_{LL} V = 2 \end{aligned} \quad (7)$$

其中, $C_{HH} = X_H X_H^T$ 表示样本集 X_H 的协方差矩阵; $C_{LL} = X_L X_L^T$ 表示样本集 X_L 的协方差矩阵; $C_{HL} = X_H X_L^T$, 表示样本集 X_H 和 X_L 的互协方差矩阵; S 由式(3)所得, 其中所用样本集为 $[X_H; X_L]$; D 为对角矩阵, 对角线元素 $D_{ii} = \sum_j S_{ij}$; L 为拉普拉斯矩阵, $L = D - S$ 。

利用 Lagrange 乘子法, 解决式(7)的最大化问题, Lagrange 函数为:

$$\begin{aligned} L(U, V, \lambda) = & U^T X_H X_L^T V - U^T X_H L X_H^T U - \\ & U^T X_H L X_L^T V - V^T X_L L X_H^T U - \\ & V^T X_L L X_L^T V - \\ & \lambda(U^T X_H X_L^T U + V^T X_L X_L^T V - 2) \end{aligned} \quad (8)$$

对式(8)进行求导, 将最优化问题转变为求特征值的问题:

$$\begin{bmatrix} A_1 & A_2 \\ B_1 & B_2 \end{bmatrix} \begin{bmatrix} U \\ V \end{bmatrix} = \lambda \begin{bmatrix} 2X_H X_H^T & 0 \\ 0 & 2X_L X_L^T \end{bmatrix} \begin{bmatrix} U \\ V \end{bmatrix} \quad (9)$$

其中:

$$\begin{aligned} A_1 &= -2X_H L X_H^T, A_2 = X_H (I - L^T - L) X_L^T \\ B_1 &= X_L (I - L^T - L) X_H^T, B_2 = -2X_L L X_L^T \end{aligned} \quad (10)$$

将特征值从大到小按递减顺序排列, 取前 d 个特征值所对应的特征向量, 其中, 前 k 行即为高分辨率图像的投影矩阵 U , 后 l 行即为低分辨率图像的投影矩阵 V :

$$\begin{aligned} U &= [u_1, u_2, \dots, u_d] \in \mathbb{R}^{k \times d} \\ V &= [v_1, v_2, \dots, v_d] \in \mathbb{R}^{l \times d} \end{aligned} \quad (11)$$

高分辨率图像 X_H 和低分辨率图像 X_L 在 CELPP 子空间投影后的所得数据分别为:

$$\begin{aligned} Y_H &= U^T X_H, Y_H = \{y_1^h, y_2^h, \dots, y_N^h\} \in \mathbb{R}^{d \times N} \\ Y_L &= V^T X_L, Y_L = \{y_1^l, y_2^l, \dots, y_N^l\} \in \mathbb{R}^{d \times N} \end{aligned} \quad (12)$$

3.2 关系学习

CELPP 的目标是寻找投影子空间, 使得投影后的高分辨率图像与低分辨率图像相关性最大, 而关系学习^[12]的目标是对相关子空间中的高分辨率图像与低分辨率图像建立映射, 从而达到有效提高低分辨率图像分辨率及清晰度的要求。

径向基网络 RBF 也能够达到建立映射的目的, 但是相比于关系学习, RBF 在构建超分辨率图像时, 效果差于关系学习的方法, 且 RBF 无法提高低分辨率训练图像的分辨率, 这一缺陷将不利于计算人脸图像的识别率。关系学习的目标函数如下所示:

$$\min_R \varepsilon(R) = \frac{1}{N} \sum_{i=1}^N (\|y_i^h - R y_i^l\|^2) + \beta \|DR - I\|^2 \quad (13)$$

其中, R 为映射矩阵; $\varepsilon(R)$ 表示映射误差; 误差越小, R 越有效, Y 越接近于原始高分辨率图像 Y_H ; β 为正规化参数; D 表示下采样矩阵; I 表示单位矩阵。低分辨率图像 Y_L 映射后得到的高分辨率图 Y 如下所示:

$$Y = R Y_L \quad (14)$$

式(13)可由梯度递减法求得。如式(15)所示, 经过 z 次迭代, 当 $R^{(z)}$ 和 $R^{(z-1)}$ 间的差值非常小时, $R^{(z)}$ 即为相关子空间中高分辨率图与低分辨率图之间的映射矩阵 R :

$$R^{(z)} = R^{(z-1)} - \alpha \frac{\partial \varepsilon(R)^T}{\partial R} \quad (15)$$

其中, α 表示递减的长度, 在本文中经实验分析, 默认 $\alpha = \frac{1}{(R^1 - R^0)}$ 。

3.3 算法流程

已知 M 张低分辨率测试图像 $P_L = \{p_1^L, p_2^L, \dots, p_M^L\} \in \mathbb{R}^{1 \times M}$, 算法目标是求其对应的高分辨率图像 P , $P = \{p_1, p_2, \dots, p_M\} \in \mathbb{R}^{k \times M}$, 算法流程如下:

Step 1 将低分辨率测试图像中心化。

Step 2 如同式(12), 将中心化后的测试样本投影至低分辨率图像的相关子空间中。

Step 3 如式(14)所示, 将映射矩阵 R 乘以 Step2 所得的投影矩阵, 得到矩阵 $Q = \{q_1, q_2, \dots, q_M\} \in \mathbb{R}^{d \times M}$, Q 为所求矩阵 P 在高分辨率图像相关子空间中的投影矩阵。

Step 4 将 Step3 所得的矩阵 Q 按照 Step2、Step1 的步骤顺序作逆运算, 即可得到高分辨率图像 P , 其中, 第 i 幅低分辨率测试图像 p_i^L 提高分辨率后得到的高分辨率图像 p_i 可表示为 $p_i = U q_i + \mu_H$ 。

4 实验结果

本文实验中使用了 ORL 以及 Yale 库 2 个人脸库。ORL 人脸库中共有 40 个人的脸图像, 其中每个人有 10 幅 32×32 的高分辨率图像, 每幅图像在表情、姿态、尺度、光照等方面都有着不同程度的变化。Yale 人脸库中共有 15 个人的脸图像, 其中每个人有 11 幅 32×32 的高分辨率图像。

将实验库中所有 32×32 的图像经过下采样操作, 得到 8×8 的低分辨率图像, 如图 1 所示。其中, 图 1(a)表示下采样后得到的低分辨率图像; 图 1(b)表示低分辨率图像经过 CELPP 和关系学习提高分辨率后得到的高分辨率图像; 图 1(c)表示原始的高分辨率图像。



图 1 ORL 及 Yale 库中部分人脸图像

本文实验中主要比较了 3 种特征提取的方法, 即 CCA、LPP 以及本文方法 CELPP, 下列实验中还涉及了 2 种关系映射的方法, RBF 以及关系学习的方法, 因此, 在实验数据比较时, 共有 6 种组合方法, 即 CELPP&RL、CCA&RL、LPP&RL、CELPP&RBF、CCA&RBF^[5]、LPP&RBF^[6]。本文实验分 2 步, 首先是提高图像的分辨率, 其次通过最近邻分类器判断测试图像所属类别, 计算识别率。

4.1 ORL 人脸库

在 ORL 人脸库中, 每类图像共有 10 幅表情、神态、光照各异的人脸图像, 灰度级为 256, 其中, 选取 5 幅作为训练图像, 剩余 5 幅作为测试图像。实验结果如表 1 所示。表 1 说明了式(9)中所选取的特征维度 d 对识别率的影响。实验证明, 当维度为 30 时, 平均识别率最高; 当维度过大时, 会使得噪声影响过大, 不仅不利于识别率的增加, 还会加大计算量, 增加运算时间。比较表 1 中不

同方法在不同维度下的识别率,可以看出本文方法明显优于其他方法。

表1 ORL 库各算法在不同维度下的识别率

方法	维度				
	10	20	30	40	50
CELPP&RL	0.93	0.95	0.97	0.98	0.97
CCA&RL	0.89	0.94	0.96	0.94	0.94
LPP&RL	0.87	0.93	0.96	0.95	0.95
CELPP&RBF	0.90	0.94	0.97	0.96	0.97
CCA&RBF	0.86	0.91	0.95	0.93	0.94
LPP&RBF	0.85	0.92	0.94	0.94	0.93

由于 RL 和 RBF 对计算时间的影响比较大,因此比较 CELPP&RL 和 CELPP&RBF 在维度为 40 时的计算时间,CELPP&RL 的计算时间为 4.1 s,CELPP&RBF 的计算时间为 2.2 s。实验结果表明,虽然 RL 虽然有助于提高识别率,但是由于 RL 计算过程中涉及了迭代操作,将会花费更多的运算时间。

4.2 Yale 人脸库

在 Yale 库中,每类图像共有 11 幅人脸图像,选取其中的 6 幅作为训练图像,剩余的 5 幅作为测试图像。实验结果如表 2 所示。

表2 Yale 库各算法在不同维度下的识别率

方法	维度				
	10	20	30	40	50
CELPP&RL	0.74	0.79	0.83	0.82	0.79
CCA&RL	0.68	0.74	0.77	0.78	0.76
LPP&RL	0.67	0.74	0.78	0.76	0.76
CELPP&RBF	0.73	0.77	0.83	0.81	0.81
CCA&RBF	0.64	0.75	0.76	0.77	0.76
LPP&RBF	0.62	0.72	0.77	0.72	0.71

实验表明,当维度较小时,本文方法的优势越为明显;当维度为 30 时,本文方法在 Yale 库中的识别率最大,为 0.83。比较表 1、表 2 中的数据,将本文方法用于 Yale 人脸库时,与其他方法相比更有优势,这说明本文方法对于光照、表情、姿态等外部因素的影响更具有鲁棒性。

5 结束语

本文提出一种相关性增强的局部保持投影(CELPP)方法,该方法在保持人脸流形结构的同时,能够保证所提取的高分辨率图像特征与低分辨率图像特征之间有着最大的相关性。与其他的超分辨率方法相比,本文方法同时具备了 LPP 与 CCA 的优点,因此在基于人脸图像的超分辨率中有着更好的适用性。本文使用 CELPP 对低分辨率测试图像提取特征,然后通过映射矩阵得到其对应的高分辨率图像,最后使用最近邻分类器对人脸图像作识别处

理。实验结果表明,CELPP 在低分辨率人脸图像的应用中有着较高的识别率。下一步研究可以在 CELPP 的基础上加入核信息,并测试其在通用图像中的适用性。

参考文献

[1] Harris J L. Diffraction and Resolving Power[J]. Journal of the Optical Society of America, 1964, 54(7): 931-936.

[2] Baker S, Kanade T. Hallucinating Faces[C]//Proc. of the 4th International Conference on Automatic Face and Gesture Recognition. Grenoble, France: IEEE Press, 2000: 83-88.

[3] Liu Ce, Shum H Y, Zhang Changshui. A Two-step Approach to Hallucinating Faces: Global Parametric Model and Local Nonparametric Model[C]//Proc. of 2001 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. [S. l.]: IEEE Press, 2001: 627-634.

[4] Huang Hua, He Huiting, Fan Xin. Super-resolution of Human Face Image Using Canonical Correlation Analysis[J]. Pattern Recognition, 2010, 43(7): 2532-2543.

[5] Huang Hua, He Huiting. Super-resolution Method for Face Recognition Using Nonlinear Mappings on Coherent Features[J]. IEEE Transactions on Neural Network, 2011, 22(1): 121-130.

[6] Chang Hong, Yeung D Y, Xiong Yimin. Super-resolution Through Neighbor Embedding[C]//Proc. of IEEE Computer Society Conference on Computer Vision and Pattern Recognition. [S. l.]: IEEE Press, 2004: 275-282.

[7] Yang Jianchao, Wright J, Huang T. Image Super-resolution as Sparse Representation of Raw Image Patches[C]//Proc. of IEEE Computer Society Conference on Computer Vision and Pattern Recognition. [S. l.]: IEEE Press, 2008: 1-8.

[8] He Xiaofei, Yan Shuicheng, Hu Yuxiao. Learning a Locality Preserving Subspace for Visual Recognition[C]//Proc. of the 9th IEEE International Conference on Computer Vision. [S. l.]: IEEE Press, 2003: 385-393.

[9] 候书东, 孙权森, 夏德森. 一种监督的局部保持典型相关分析算法[J]. 模式识别与人工智能, 2012, 25(1): 143-149.

[10] Zhuang Yueting, Zhang JIAN, Wu Fer. Hallucinating Faces: LPH Super-resolution and Neighbor Reconstruction for Residue Compensation[J]. Pattern Recognition, 2007, 40(11): 3178-3194.

[11] Hotelling H. Relations Between Two Sets of Variates[J]. Biometrika, 1936, 28(3): 321-377.

[12] Wilman W, Zou W, Pong C. Very Low Resolution Face Recognition Problem[J]. IEEE Transactions on Image Processing, 2012, 21(1): 327-341.

编辑 索书志